

Alphabet $A = \{x_1 \rightarrow x_K\}$.

Prob. distribution $p_k = P(X=x_k)$ (typog^t - empiriq^t)

Code $C_k = c(x_k)$, longueur $|c_k|$


longueur moyenne: $L(c) = E_x(|c(x)|)$

Code prefixe: ~~...~~ $C = \text{Feuilles}(T)$ (= longueur
texte codé / #
symbole)

Pbm: $\min_{C=\text{Feuille}(T)} L(c)$



Def: $H(p) \triangleq \sum_k -p_k \log_2(p_k)$



Prop: $0 \leq H(p) \leq \log_2(N)$

Preuve: $\min_{(p_k)} \sum p_k \log p_k$ at $\begin{cases} p_k \geq 0 \\ \sum_k p_k = 1 \\ g(p) = 1 \end{cases}$

sol: $\Rightarrow \exists \lambda$ tq. $\nabla f(p) = \lambda \nabla g(p)$


$\left[\frac{d}{dx} [x \log x] = \log x + 1 \right] \Rightarrow \log p_k + 1 = \lambda \Rightarrow p_k = 2^{\lambda-1}$ - or the
 $\sum p_k = 1 \Rightarrow p_k = 1/N$ (unique sol.)

$$H\left(\left(\frac{1}{N}\right)\right) = \sum_k \frac{1}{N} \log_2\left(\frac{1}{N}\right) = \log_2(N)$$

Thm: $\exists c = \text{Feuille}(T), L(c) \geq H(p)$

Lemma: (ineq de Kraft) $\sum_{k=1}^{\infty} 2^{-l_k} \leq 1 \quad \forall c = \text{Feuille}(T)$

Dem A:



$\square B$ si $\sum 2^{-l_k} \leq 1$, alors $\exists c$ tq. $|c| = l_k$

$\text{Prof}(T_k) = m - l_k, |\text{Feuille}(T_k)| = 2^{m-l_k}$

\hat{C} les T_k sont disjointes, $\sum_k |\text{Feuille}(T_k)| \leq |\text{Feuille}(T)|$

$\Rightarrow \sum 2^{m-l_k} \leq 2^m \iff \sum 2^{-l_k} \leq 1$

~~Remarque~~ $\square A$ ONS que $l_1 \leq \dots \leq l_k, m \triangleq \max\{l_1, \dots, l_k\}$

Algo: $\bullet T_1$ le 1^{er} arbre de prof: $m-l_1$
 $\bullet T_2$ le 2^e arbre de profondeur $m-l_2$
 $\bullet T_3$ etc...



ex: $l_1=1$
 $l_2=2$
 $l_3=3$
 $\frac{1}{2} + \frac{1}{4} + \frac{1}{8} \leq 1$

$\hat{C} \sum 2^{m-l_k} \leq 2^m$ on peut terminer cette construction.

• les mots c_k sont associés aux sommets des arbres

Preuve (thm entropie shanon).

On considère : $\min_{(l_k)} \sum p_k l_k$ st. $\sum 2^{-l_k} \leq 1$

⊛ Montrer que nec^t $\sum 2^{-l_k} = 1$ $f(l)$

$\exists \lambda$ tq. $\nabla f(l) = \lambda \nabla g(l)$

$$\left(\frac{d}{du} 2^{-u} \right) = -\ln(2) 2^{-u}$$

$$\Rightarrow (p_k)_k = -\lambda \ln(2) 2^{-l_k}$$

~~$\sum p_k l_k = -\lambda \ln(2) \sum 2^{-l_k} l_k$~~

$$\Rightarrow \sum_{k=1}^n p_k = -\lambda \ln(2) \sum_{k=1}^n 2^{-l_k} \Rightarrow -\lambda \ln 2 = 1$$

$$\Rightarrow \text{sol}^c \quad l_k^* = -\log(p_k)$$

[On définit (pour avoir des nbr entiers) $l_k \triangleq \lceil -\log(p_k) \rceil$]

Alors comme Preuve [1]: si $C = \text{feuille}(T)$ avec Kraft [A] $\sum 2^{-|C_k|} \leq 1$ donc nec^t $(l_k)_k$ est meilleur que $(|C_k|)_k$ donc $\sum p_k l_k^* \leq \sum p_k |C_k|$

$$= H(P).$$

$$= L(C)$$

Preuve [2]: on définit $l_k \triangleq \lceil -\log(p_k) \rceil \in \mathbb{N}^+$ alors

$$\sum_k 2^{-l_k} \leq \sum_k 2^{-\log(p_k)} = \sum_k p_k = 1$$

donc avec Kraft [B] \exists code $C = \text{feuille}(T)$ $|C_k| = l_k$

$$L(C) = \sum_k p_k \lceil -\log(p_k) \rceil \leq \sum_k p_k (-\log(p_k) + 1) = H(P) + 1$$

⊛ Si $\sum 2^{-l_k} = 2^{-u} < 1 \Rightarrow \sum 2^{-(l_k - u)} = 1$

et $\sum p_k l_k' = \sum p_k l_k - u \sum p_k < \sum p_k l_k \Rightarrow$ contradiction

Preliminaire